PROYECTO FINAL · ANALÍTICA DE DATOS I · 2026-02

Proyecto 2: Potencia de una Planta Solar – Regresión (Planta 2)

Predicción de la potencia AC y segmentación de días en una planta con pérdidas operativas

Modalidad	Un (1) equipo de 4 personas
Peso en la nota final	30 % (Proyecto Final)
Duración	4 semanas: del miércoles 28 de octubre al miércoles 25 de noviembre de 2026
Entrega de notebook, informe y diapositivas	Martes 24 de noviembre de 2026, 11:59 p. m.
Sustentación	Miércoles 25 de noviembre de 2026 (semana 17)
Uso de IA generativa	Nivel 3 – Colaboración con IAG (máximo permitido). Ver la sección "Reglas de juego: uso de IA generativa".
Datos	Descargados por el grupo desde Kaggle (cuenta gratuita): https://www.kaggle.com/datasets/anikannal/solar-power-generation-data. Trabajo en Jupyter local o Google Colab. Usar solo los archivos de la Planta 2.

Contexto del Caso

Una **empresa de operación y mantenimiento (O&M) de plantas solares** quiere ofrecer sus servicios en Colombia y necesita herramientas analíticas para vigilar el desempeño de las plantas. Para desarrollarlas usará datos reales de la **Planta 2** de un conjunto publicado en Kaggle: la potencia de sus **22 inversores** medida cada 15 minutos durante 34 días (15 de mayo al 17 de junio de 2020) y un sensor de irradiación y temperatura en la planta.

Problema: la empresa no tiene una referencia de cuánta potencia debería entregar la planta en cada momento según el clima. Sin esa referencia no puede distinguir una caída de potencia causada por nubes de una causada por fallas, desconexiones o suciedad, ni planear el mantenimiento con datos.

En este proyecto se trabaja con la **planta completa** (no con cada inversor): la potencia de la planta en cada instante, **AC_PLANTA_KW**, es la suma de la potencia AC de todos sus inversores. Trabajando solo con las horas de sol, deben resolver la siguiente tarea:

- **Regresión** predecir **AC_PLANTA_KW** (kW) en cada instante de 15 minutos a partir de las mediciones del sensor en ese instante, la hora y, si lo deciden, los valores pasados de la potencia.
- **Alcance:** el modelo estima la potencia del instante siguiente (t + 1) con información disponible de instantes anteriores en t.

Objetivos y Resultados Esperados

Objetivo general

Construir y evaluar un modelo de regresión que estime la potencia AC de la Planta 2 a partir de las condiciones medidas, y explicar qué variables la determinan.

Objetivos específicos

- Documentar el contexto energético y operativo de la planta y formular dos o tres preguntas analíticas (Tarea 1).
- Construir un dataset limpio de la planta, con las decisiones de calidad de datos justificadas (Tarea 2).
- Comparar las líneas base (irradiación sola y persistencia) con una regresión lineal múltiple y un árbol de decisión, usando validación cronológica (Tarea 3).
- Segmentar los días con K-Means y relacionar los grupos con los errores del modelo (Tarea 3).
- Interpretar los resultados, responder las preguntas analíticas y proponer cómo usaría la empresa el modelo (Tarea 4 y sustentación).

Resultados esperados

Al final del proyecto el grupo debe presentar, en el notebook y en el informe:

- El dataset de la planta (AC_PLANTA_KW, variables del sensor y variables construidas) y un resumen de las decisiones de calidad de datos.
- Una tabla comparativa con R^2, RMSE y MAE en el conjunto de prueba para todos los modelos, incluidas las líneas base.
- El gráfico de valores reales vs. predichos y el análisis de residuos del mejor modelo.
- La interpretación de los coeficientes y de la importancia de variables, conectada con la Tarea 1.
- Los grupos de días encontrados con K-Means, su interpretación y el error del modelo en cada grupo.
- La respuesta a las preguntas analíticas y una recomendación concreta para la empresa.

No se exige un valor mínimo de las métricas. Se evalúan la calidad de la preparación de los datos, la validación, la comparación contra las líneas base y sobre todo la interpretación de los resultados, según la rúbrica.

Recursos Disponibles

Recurso	Dónde encontrarlo	Para qué sirve
Datos	Kaggle (cuenta gratuita, botón Download): https://www.kaggle.com/datasets/anikannal/solar-power-generation-data	Usar solo Plant_2_Generation_Data.csv y Plant_2_Weather_Sensor_Data.csv
Diccionario de datos	Anexo A de este documento	Significado y unidades de cada columna
Ayudas de código probadas	Anexo B de este documento	Ubicar los datos, crear rezagos y calcular la línea base de persistencia
Plantilla del informe	Plantilla IEEE del curso ("Formato presentación documentos") en la plataforma del curso	Formato obligatorio del informe
Rúbrica	Sección "Rúbrica de evaluación" de este documento	Criterios, pesos y evidencias que se calificarán
Acompañamiento	Sesiones 13 a 16: asesoría y revisión de avances	Resolver dudas antes de la entrega

Ruta del Proyecto (CRISP-DM)

El proyecto sigue las fases de la metodología CRISP-DM vista en la sesión 2. Cada tarea de este enunciado corresponde a una o más fases:

Fase CRISP-DM	Tarea del proyecto	Pregunta que responde
Comprensión del negocio	Tarea 1: Contexto Energético y Operativo de la Planta	¿Qué problema operativo tiene la empresa de O&M, qué factores físicos y de operación explican la generación de la planta y qué preguntas analíticas vamos a responder?
Comprensión de los datos	Tarea 2 (datos de Kaggle y EDA)	¿Qué datos tenemos, qué tan completos son y qué patrones muestran?
Preparación de los datos	Tarea 2 (faltantes, atípicos, variables)	¿Qué decisiones de limpieza y transformación tomamos y por qué?
Modelado	Tarea 3	¿Qué modelos usamos y cómo ajustamos sus hiperparámetros?
Evaluación	Tareas 3 y 4	¿El modelo supera la línea base y responde las preguntas del negocio?
Despliegue (propuesta)	Tarea 4 (conclusiones) y sustentación	¿Cómo usaría la empresa el modelo y qué haría falta para ponerlo en operación?

Cronograma Sugerido (4 Semanas)

Las fechas de **entrega (martes 24 de noviembre)** y de **sustentación (miércoles 25 de noviembre)** son obligatorias. Las metas semanales son una guía; las revisiones de las sesiones son formativas y no se califican por separado.

Sem.	Fechas	Qué deben hacer	Producto de la semana	En clase
1	28 oct – 3 nov	Tarea 1 (contexto y preguntas analíticas) y descarga de los datos desde Kaggle, preparación del entorno y construcción de la serie de la planta	Introducción con fuentes y datos cargados	Sesión 13 (28 oct): atípicos e imputación
2	4 – 10 nov	Tarea 2: calidad de datos, faltantes, atípicos y EDA	Dataset limpio y gráficos del EDA	Sesión 14 (4 nov): asesoría del proyecto
3	11 – 17 nov	Tarea 3: modelos de regresión/forecasting con validación, más K-Means de días	Tabla comparativa de modelos	Sesión 15 (11 nov): Parcial 3 y avances
4	18 – 24 nov	Tarea 4: informe IEEE, limpieza del notebook y diapositivas	Entrega final (martes 24 nov)	Sesión 16 (18 nov): revisión de avances
—	25 nov	Sustentación	Presentación y defensa	Semana 17 (miércoles 25 nov)

Reglas de Juego: Uso de IA Generativa

De acuerdo con los acuerdos sobre IAG del syllabus del curso y el Manifiesto sobre IA y educación de la Universidad Icesi, este proyecto se desarrolla como máximo en el **Nivel 3 – Colaboración con IAG**. Pueden apoyarse en la IAG para completar tareas y mejorar sus productos, pero llevando un registro de sus interacciones y demostrando que entienden y pueden modificar todo lo generado.

Qué está permitido

- Pedir explicaciones de conceptos, de funciones de pandas y scikit-learn o de mensajes de error.
- Generar o depurar fragmentos de código (gráficos, limpieza, ajuste de modelos), siempre que el grupo lo revise, lo ejecute, lo entienda y pueda modificarlo.
- Mejorar la redacción y la ortografía del informe y de las diapositivas.
- Buscar fuentes para la Tarea 1, verificando cada una en el documento original antes de citarla.

Qué no está permitido

- Entregar código, texto o figuras que ningún integrante pueda explicar o modificar.

- Delegar en la IAG las decisiones del proyecto y su sustentación (qué variables usar, cómo tratar faltantes y atípicos, qué modelo elegir) o la interpretación de resultados, la discusión y las conclusiones: esas son las evidencias de aprendizaje que se evalúan.
- Citar fuentes, cifras o resultados sin verificarlos: la IAG puede inventar referencias y datos.

Registro y declaración (obligatorios)

- **Declaración en el informe:** un párrafo antes de las referencias con el nivel usado, las herramientas, para qué se usaron y cómo se verificó lo generado.

Cómo se verifica

- En la sustentación, cualquier integrante puede ser llamado a explicar o modificar en vivo cualquier parte del notebook o del informe. La rúbrica (criterio 5, 30 %) ubica en nivel Developing la "dependencia significativa de herramientas de IA sin comprensión plena de lo generado".
- Entregar sin registro, con contenido que el grupo no puede explicar o con fuentes inventadas afecta la calificación de los criterios correspondientes y puede tratarse como falta a la integridad académica según el reglamento de la Universidad.

Contexto Energético y Operativo de la Planta (Tarea 1)

Investiguen y documenten en la introducción del informe, con al menos **cinco fuentes confiables** citadas en formato IEEE (UPME, XM, CREG, IDEAM, artículos científicos):

- **Energía solar en Colombia:** ¿cuánta capacidad solar tiene el Sistema Interconectado Nacional y cómo ha crecido? ¿Qué promueven la Ley 1715 de 2014 y la Ley 2099 de 2021?
- **Física de la planta:** ¿cómo dependen la potencia de la irradiación y de la temperatura del módulo? ¿Qué hace un inversor y por qué la potencia AC es menor que la DC?
- **Operación y mantenimiento:** ¿qué causa pérdidas en una planta solar (temperatura, suciedad, sombras, desconexiones, saturación del inversor)? ¿Qué es el performance ratio?
- **Estado del arte:** ¿cómo se usa el machine learning para pronosticar la potencia de plantas solares y qué variables resultan más importantes?

Preguntas analíticas

Con base en lo investigado, formulen **dos o tres preguntas analíticas** que su proyecto responderá con los datos, y retómenlas en la discusión. Ejemplo: "¿Cuánta potencia pierde la planta por cada grado que sube la temperatura del módulo?"

Comprensión y Preparación de los Datos (Tarea 2)

2.1 Descarga y construcción del dataset de la planta

- **Descarga:** entren a la página del dataset en Kaggle (cuenta gratuita), usen el botón **Download** y guarden el ZIP (archive.zip). Kaggle se usa solo para descargar los datos; el trabajo se hace en **Jupyter en su equipo** (recomendado) o en **Google Colab**.
- **Local:** creen una carpeta del proyecto, pongan allí el notebook y el ZIP (o los CSV descomprimidos) e instalen las librerías con `pip install pandas scikit-learn matplotlib`. **Colab:** suban el ZIP con el panel de archivos (queda en /content) o léanlo desde Google Drive. En ambos casos la función `buscar_datos` del Anexo B encuentra los CSV y descomprime el ZIP si hace falta.
- Usen solo **Plant_2_Generation_Data.csv** (potencia por inversor) y **Plant_2_Weather_Sensor_Data.csv** (sensor de la planta).
- Sumen la potencia AC de los inversores en cada instante para obtener **AC_PLANTA_KW** y unan el resultado con el sensor por fecha-hora. Creen variables derivadas justificadas (por ejemplo, la hora del día en decimal).

2.2 Selección de variables

- Elijan y justifiquen los predictores con base en la Tarea 1. El sensor aporta tres variables: IRRADIATION, MODULE_TEMPERATURE y AMBIENT_TEMPERATURE; a ellas se suman las variables de calendario que construyan (por ejemplo, la hora). Como el modelo estima el instante t + 1, las variables del sensor solo pueden entrar con su valor en t o en instantes anteriores: su valor en t + 1 todavía no se conoce.
- **Valores pasados (rezagos):** pueden usar como predictores valores anteriores de AC_PLANTA_KW (por ejemplo, de hace 15, 30 y 60 minutos), porque en la operación ya se conocen al momento de estimar. Calcúlenlos con la fecha y no con la posición de la fila, y antes de filtrar las horas de sol (función `agregar_rezagos` del Anexo B). Comparen los modelos con y sin rezagos: ¿cuánto aporta el clima por encima de la historia de la señal?
- **Justifiquen lo que descartan** la potencia DC y las energías acumuladas (DAILY_YIELD, TOTAL_YIELD) se calculan a partir de la misma potencia que se quiere predecir; usarlas es fuga de información. Lo mismo ocurre con AC_PLANTA_KW del mismo instante: solo sus valores pasados son válidos.

2.3 Faltantes, atípicos y calidad de datos

- **Registros ausentes:** calculen cuántos instantes de 15 minutos deberían existir en el periodo y cuántos faltan en cada archivo.
- **Instantes incompletos:** cuenten cuántos inversores reportan en cada instante. Si faltan inversores, la suma subestima la potencia de la planta: decidan si excluir esos instantes o corregirlos, y justifiquen.
- **Cero estructural:** de noche la potencia y la irradiación son cero; eso no es un faltante. Filtren las horas de sol y justifiquen el umbral de irradiación que usen.

- **Formatos de fecha:** no son iguales en los dos archivos. Revísenlos antes de unir.
- **Error de escala:** comparen DC_POWER con AC_POWER. ¿La relación es físicamente posible? Documenten el hallazgo, aunque la potencia DC no se use como predictor.
- **Atípicos:** identifíquenlos con una técnica estadística sencilla (rango intercuartílico o puntaje z, sesión 13) y decidan, caso por caso, si son errores de registro o eventos reales. No eliminen datos sin justificarlo.
- **Imputación:** usen técnicas sencillas y justificadas (mediana por grupo, interpolación en el tiempo). Si imputan, comparen la distribución antes y después.

2.4 Análisis exploratorio

- Histograma y boxplot de AC_PLANTA_KW: ¿cómo es su distribución?, ¿hay días atípicos (por ejemplo, nublados)?
- AC_PLANTA_KW vs. IRRADIATION (¿es lineal en todo el rango?), MODULE_TEMPERATURE vs. AMBIENT_TEMPERATURE, perfil diario promedio de potencia y matriz de correlación.

Modelado y Evaluación (Tarea 3)

Vayan de lo simple a lo complejo y comparen siempre contra una línea base. Todo con scikit-learn, como en las sesiones 8 a 10.

3.1 Regresión: potencia AC de la planta

- **Línea base:** regresión lineal simple con la irradiación del instante anterior (IRRADIATION_lag1) como única variable. Interpreten su pendiente: ¿cuántos kW entrega la planta por cada kW/m² de irradiación? Como segunda línea base usen la **persistencia**: la potencia de los 15 minutos anteriores (AC_PLANTA_KW_lag1).
- **Regresión lineal múltiple:** interpreten el signo y la magnitud de los coeficientes (estandaricen las variables para comparar su efecto) y revisen los supuestos con el gráfico de residuos vs. valores predichos y el histograma de residuos. Opcional: p-values con statsmodels.
- **Árbol de decisión de regresión:** elijan la profundidad máxima con validación cruzada.
- **Métricas:** R^2, RMSE y MAE en el conjunto de prueba, y gráfico de valores reales vs. predichos del mejor modelo.

3.2 Validación

- Dividan los datos **cronológicamente por días**: los primeros días (aprox. 80 %) para entrenamiento y los últimos (aprox. 20 %) para prueba. Expliquen por qué no conviene mezclar al azar registros consecutivos de 15 minutos.
- Ajusten hiperparámetros con **validación cruzada de 5 particiones para series de tiempo** (TimeSeriesSplit de scikit-learn o alguna otra) sobre el entrenamiento ordenado por fecha.

- El escalado y la imputación se ajustan **solo con el conjunto de entrenamiento** (pueden usar Pipeline de scikit-learn).
- **Sobreajuste:** comparen la métrica principal en entrenamiento y en prueba para cada modelo y comenten si hay sobreajuste.
- **Interpretabilidad:** presenten la importancia de variables del árbol de decisión y relaciónenla con lo investigado en la Tarea 1.

Informe Final (Tarea 4)

Documento técnico de **máximo 5 páginas** en la plantilla IEEE del curso ("Formato presentación documentos"). No anexen el código al documento. Estructura:

- **Título, autores y resumen (150–250 palabras)** e índice de términos (cuatro palabras clave).
- **Introducción:** problema de negocio, contexto de la Tarea 1, objetivos y preguntas analíticas.
- **Materiales y métodos:** datos, variables seleccionadas, manejo de faltantes y atípicos, modelos, validación, métricas y versiones de las librerías.
- **Resultados:** tabla comparativa de todos los modelos (incluida la línea base) y las figuras principales, presentados sin interpretar.
- **Discusión:** respuesta a las preguntas analíticas, interpretación a la luz del negocio y limitaciones. Por ejemplo: "El R^2 es menor de lo esperado porque varios inversores dejaron de producir con sol; el clima no explica esas pérdidas, que son un problema de operación".
- **Conclusiones:** utilidad del modelo para la toma de decisiones, cómo lo usaría la empresa (despliegue) y mejoras concretas.
- **Declaración de uso de IAG:** un párrafo antes de las referencias con el nivel usado, las herramientas, para qué se usaron y cómo se verificó lo generado (si no usaron IAG, decláranlo).
- **Referencias** en formato IEEE.

Sustentación (miércoles 25 de noviembre)

- **Duración:** 12 minutos de presentación y 8 minutos de preguntas por grupo. Todos los integrantes presentan.
- **Contenido:** problema y preguntas analíticas, decisiones de preparación de datos, modelos y resultados, respuesta a las preguntas y recomendación para la empresa.
- **Preguntas individuales:** el docente puede pedir a cualquier integrante que explique o modifique en vivo una parte del notebook. Los criterios 1 a 4 de la rúbrica se califican por grupo; el criterio 5 (sustentación, 30 %) se califica de forma individual.

Evidencias que se Revisarán en este Proyecto

Criterio	Qué se espera ver
1. Claridad y Rigor en el Análisis	Descarga y unión correcta; construcción de la potencia de la planta; registros ausentes e instantes incompletos; ceros nocturnos; inversores sin producción con sol identificados y tratados; atípicos con IQR o z; relación potencia–irradiación analizada.
2. Desarrollo y Ajuste de los Modelos	Pendiente de la irradiación interpretada; rezagos justificados y comparados con la persistencia; coeficientes y residuos de la regresión múltiple discutidos; profundidad del árbol justificada; K-Means con codo y silhouette, grupos interpretados y usados para analizar errores; importancia de variables conectada con la operación de la planta.
3. Validación y Métricas	División cronológica por días y validación cruzada para series de tiempo; R^2, RMSE y MAE frente a la línea base; comparación entrenamiento vs. prueba; análisis crítico de por qué el clima no explica toda la variación (pérdidas operativas).
4. Comunicación de Resultados	Informe IEEE de máximo 5 páginas con tabla comparativa, real vs. predicho, residuos, grupos de días e importancia de variables, explicadas en el texto; preguntas analíticas respondidas.
5. Sustentación Oral (Presentación)	Explicar cómo se construyó la potencia de la planta, cómo se trataron los inversores sin producción, qué representa cada grupo de K-Means y defender o modificar el código sin apoyo de la IAG.

Entregables

Un solo envío por grupo en la plataforma del curso, a más tardar el **martes 24 de noviembre de 2026 a las 11:59 p. m.**, en un archivo ZIP llamado **Proyecto2_Grupo_ApellidosMiembros.zip** con los tres archivos siguientes. No incluyan los CSV del dataset.

- **Notebook (.ipynb, Jupyter local o descargado de Google Colab):** documentado, ejecutado de principio a fin con las salidas visibles y con semilla aleatoria fija (random_state = 42).
- **Informe final:** PDF de máximo 5 páginas en la plantilla IEEE del curso.
- **Diapositivas** de la sustentación (PDF).

Rúbrica de Evaluación

Criterio	Peso	Outstanding (4.5 – 5.0)	Proficient (3.8 – 4.5)	Developing (3.0 – 3.8)	Beginning (0 – 3.0)
1. Claridad y Rigor en el Análisis	17.5 %	El EDA está bien estructurado, con gráficos claros y justificaciones sólidas y profundas sobre cada decisión de preprocesamiento.	El EDA está completo y ordenado, con justificaciones adecuadas para las decisiones tomadas.	El EDA presenta cierta estructura, pero carece de justificaciones claras o consistencia en las decisiones.	El EDA es superficial, desorganizado o con ausencia de justificaciones relevantes.
2. Desarrollo y Ajuste de los Modelos	17.5 %	Implementación e interpretación correcta de modelos; se interpretan correctamente los resultados, se discuten supuestos y se analizan las variables relevantes.	Modelos correctamente implementados; interpretación y análisis adecuados, aunque con menor profundidad.	Modelos funcionales, pero con errores de interpretación o sin discusión de supuestos/variables.	Modelos mal implementados o no interpretados; sin relación con los objetivos del taller.
3. Validación y Métricas	17.5 %	Aplicación de validación cruzada o estrategias pertinentes; uso acertado de métricas y análisis crítico profundo.	Validación bien ejecutada y métricas adecuadas; el análisis crítico es correcto, aunque puede mejorar.	Uso básico de validación y métricas; análisis poco crítico o limitado.	Validación incorrecta o ausente; métricas mal utilizadas o mal interpretadas.
4. Comunicación de Resultados	17.5 %	Informe claro, bien estructurado y argumentado; visualizaciones claras, relevantes y bien explicadas.	Informe claro y coherente; visualizaciones adecuadas, aunque podrían mejorar en diseño o explicación.	Informe con deficiencias de estructura o claridad; visualizaciones poco efectivas o incompletas.	Informe confuso o incompleto; visualizaciones ausentes o sin valor analítico.
5. Sustentación Oral (Presentación)	30 %	Domina con seguridad los conceptos técnicos y metodológicos del trabajo; justifica cada decisión (preprocesamiento, selección de modelo, métricas) con argumentos propios y contextualizados; explica y defiende su código sin depender de notas, respondiendo con solvencia preguntas no anticipadas.	Explica con claridad la mayoría de los conceptos y decisiones del trabajo, aunque con menor profundidad en algunos puntos; justifica adecuadamente las decisiones metodológicas; explica su código de forma correcta, con apoyo ocasional en notas o documentación propia.	Presenta el trabajo con explicaciones superficiales o memorísticas; tiene dificultad para justificar decisiones metodológicas sin ayuda del evaluador; su explicación del código es parcial o evidencia dependencia significativa de herramientas de IA sin comprensión plena de lo generado.	No logra explicar los conceptos ni justificar las decisiones tomadas; no puede explicar o defender el código presentado; depende casi por completo de las indicaciones del evaluador para sostener cualquier parte de la presentación.

Anexo A: Diccionario de Datos (Planta 2)

Periodo: 15-may-2020 a 17-jun-2020, registros cada 15 minutos. El archivo de sensores contiene solo las seis columnas indicadas; AC_PLANTA_KW la construyen ustedes. Las que aparecen con la clasificación "Construida", son variables que no están explicitas en el conjunto de datos, sino que debe ser construida por el equipo, algunas de ellas con las ayudas de código ubicadas al final o el código que consideren pertinente.

Variable	Archivo	Descripción	Unidad
DATE_TIME	Ambos	Fecha y hora del registro	—
PLANT_ID	Ambos	Identificador de la planta	—
SOURCE_KEY	Ambos	Generación: identificador del inversor (solo para sumar y contar). Sensores: identificador del sensor	—
DC_POWER	Generación	Potencia DC que entra al inversor	kW
AC_POWER	Generación	Potencia AC que entrega el inversor	kW
DAILY_YIELD / TOTAL_YIELD	Generación	Energía acumulada del inversor en el día / total	kWh
AMBIENT_TEMPERATURE	Sensores	Temperatura ambiente de la planta	°C
MODULE_TEMPERATURE	Sensores	Temperatura del módulo	°C
IRRADIATION	Sensores	Irradiación sobre el plano del módulo (promedio de 15 min)	kW/m²
AC_PLANTA_KW	Construida	**Variable objetivo:** suma de AC_POWER de todos los inversores en el instante	kW
AC_PLANTA_KW_lag1 / _lag2 / _lag4	Construida	Potencia de la planta 15, 30 y 60 minutos antes (predictores permitidos)	kW
Sensor: <variable>_lag1 / _lag2 / _lag4	Construida	IRRADIATION, AMBIENT_TEMPERATURE y MODULE_TEMPERATURE 15, 30 y 60 minutos antes (predictores permitidos)	kW/m², °C

Anexo B: Ayudas de Código

Son solo funciones de apoyo y la línea base de persistencia: la construcción del dataset, la división de los datos y los modelos los programa cada grupo. Prepárense para comprender y explicar también su funcionamiento en la sustentación.

1. Ubicación de los datos descargados de Kaggle (local o Colab)

```
import glob, os, zipfile
def buscar_datos(archivo='Plant_1_Weather_Sensor_Data.csv', carpeta='.'):
    """Devuelve la carpeta donde están los CSV del dataset descargado de Kaggle.
    Antes de ejecutar: descarguen el ZIP (botón Download en Kaggle) y déjenlo, o los CSV,
    dentro de `carpeta`:
    - Local (Jupyter): la carpeta del proyecto donde está el notebook (carpeta='.').
    - Colab: súbanlo con el panel de archivos (/content, carpeta='.') o desde Google Drive
      (carpeta='/content/drive/MyDrive/<su_carpeta>').
    Si encuentra el ZIP sin descomprimir, lo descomprime en <carpeta>/datos_solar."""
    hallados = glob.glob(os.path.join(carpeta, '**', archivo), recursive=True)
    if hallados:
        return os.path.dirname(hallados[0])
    for ruta_zip in glob.glob(os.path.join(carpeta, '*.zip')):
        with zipfile.ZipFile(ruta_zip) as z:
            if any(n.endswith(archivo) for n in z.namelist()):
                destino = os.path.join(carpeta, 'datos_solar')
                z.extractall(destino)
                return buscar_datos(archivo, destino)
    raise FileNotFoundError(f'No se encontró {archivo}. Descarguen el ZIP desde Kaggle y déjenlo '
                            'en la carpeta del notebook, o indiquen la ruta con el argumento carpeta.')
ruta = buscar_datos()
print('Datos en:', ruta, '->', sorted(os.listdir(ruta)))
```

2. Función para agregar valores pasados (rezagos)

```
import numpy as np
import pandas as pd
def agregar_rezagos(df, columna, pasos=(1, 2, 4), freq='15min'):
    """Agrega a df columnas con valores pasados de `columna` (rezagos).
    pasos: intervalos hacia atrás (con freq='15min': 1 = 15 min, 2 = 30 min, 4 = 1 hora).
    El rezago se busca por fecha y no por posición de fila: si falta el registro
    anterior, el valor queda vacío (NaN) en lugar de tomar uno equivocado.
    Requiere una columna DATE_TIME sin fechas repetidas. Úsenla ANTES de filtrar las horas de sol."""
    serie = df.set_index('DATE_TIME')[columna]
    if not serie.index.is_unique:
        raise ValueError('Hay fechas repetidas: agreguen o eliminen duplicados primero.')
    for p in pasos:
        pasado = serie.shift(p, freq=freq)       # el valor de t queda asociado a t + p intervalos
        df[f'{columna}_lag{p}'] = df['DATE_TIME'].map(pasado)
    return df


# Uso: df = agregar_rezagos(df, 'NOMBRE_DE_LA_COLUMNA')   -> crea NOMBRE_lag1, NOMBRE_lag2, NOMBRE_lag4
```

3. Línea base de persistencia

```
# Línea base de persistencia: la potencia de la planta de los 15 minutos anteriores.
# Requiere el conjunto de prueba `test` con AC_PLANTA_KW y AC_PLANTA_KW_lag1 (agregar_rezagos).
from sklearn.metrics import r2_score, mean_absolute_error, mean_squared_error


te = test.dropna(subset=['AC_PLANTA_KW_lag1'])
real, pred = te['AC_PLANTA_KW'], te['AC_PLANTA_KW_lag1']
print(f'Persistencia  R2 = {r2_score(real, pred):.3f}   RMSE = {np.sqrt(mean_squared_error(real,
pred)):.1f} kW'
      f'   MAE = {mean_absolute_error(real, pred):.1f} kW')
```