PROYECTO FINAL · ANALÍTICA DE DATOS I · 2026-02

Proyecto 5: Temperatura del Módulo Solar – Regresión (Plantas 1 y 2)

Predicción de la temperatura del módulo y prueba del modelo en una segunda planta

Modalidad	Un (1) equipo de 3 personas
Peso en la nota final	30 % (Proyecto Final)
Duración	4 semanas: del miércoles 28 de octubre al miércoles 25 de noviembre de 2026
Entrega de notebook, informe y diapositivas	Martes 24 de noviembre de 2026, 11:59 p. m.
Sustentación	Miércoles 25 de noviembre de 2026 (semana 17)
Uso de IA generativa	Nivel 3 – Colaboración con IAG (máximo permitido). Ver la sección "Reglas de juego: uso de IA generativa".
Datos	Descargados por el grupo desde Kaggle (cuenta gratuita): https://www.kaggle.com/datasets/anikannal/solar-power-generation-data. Trabajo en Jupyter local o Google Colab. Usar solo los archivos de sensores de ambas plantas.

Contexto del Caso

La temperatura del módulo es una de las principales causas de pérdida de potencia en una planta solar: los paneles rinden menos cuando se calientan. Una **empresa de operación y mantenimiento (O&M)** que quiere ofrecer sus servicios en Colombia necesita estimar la **temperatura esperada del módulo** a partir del clima, para cuantificar las pérdidas por calor y detectar módulos que se calientan más de lo normal (falta de ventilación, puntos calientes).

Problema: la empresa no tiene una referencia de cuánto debería calentarse un módulo según el clima, por lo que no puede cuantificar las pérdidas por calor ni distinguir un calentamiento normal de uno anómalo. Además, necesita saber si un modelo desarrollado en una planta sirve para otra.

Para desarrollar el modelo cuenta con los **sensores de dos plantas fotovoltaicas en India**, publicados en Kaggle: irradiación, temperatura ambiente y temperatura del módulo cada 15 minutos durante 34 días (15 de mayo al 17 de junio de 2020). Deben resolver la siguiente tarea:

- **Regresión:** predecir la **temperatura del módulo** (MODULE_TEMPERATURE, °C) en cada instante de 15 minutos a partir de la temperatura ambiente, la irradiación y la hora de ese instante y, si lo deciden, los valores pasados de la temperatura del módulo. El modelo se entrena y se valida con la **Planta 1**, y luego se evalúa **sin reentrenar** en la **Planta 2**.

- **Alcance:** el modelo estima la temperatura del mismo instante (t) con información disponible en t. No se pide pronosticar el clima ni horas o días futuros.

Objetivos y Resultados Esperados

Objetivo general

Construir y evaluar un modelo de regresión que estime la temperatura del módulo a partir del clima, comprobar si funciona en una segunda planta y usarlo para cuantificar las pérdidas por calor.

Objetivos específicos

- Documentar el contexto térmico y operativo de los módulos y formular dos o tres preguntas analíticas (Tarea 1).
- Construir un dataset limpio con los sensores de ambas plantas, con las decisiones de calidad de datos justificadas (Tarea 2).
- Comparar las líneas base (temperatura ambiente sola y persistencia) con una regresión lineal múltiple y un árbol de decisión en la Planta 1, usando validación cronológica (Tarea 3).
- Evaluar el modelo en la Planta 2 sin reentrenarlo y comparar los coeficientes de ambas plantas (Tarea 3).
- Estimar las pérdidas de potencia por calor, proponer un umbral de alerta y recomendar cómo usaría la empresa el modelo (Tareas 3 y 4).

Resultados esperados

Al final del proyecto el grupo debe presentar, en el notebook y en el informe:

- El dataset de sensores de ambas plantas y un resumen de las decisiones de calidad de datos.
- Una tabla comparativa con R^2, RMSE y MAE de todos los modelos (incluidas las líneas base) en la prueba de la Planta 1 y en la Planta 2.
- El gráfico de valores reales vs. predichos y el análisis de residuos del mejor modelo.
- Los coeficientes de la regresión lineal de ambas plantas, comparados con la física investigada.
- El porcentaje estimado de pérdida de potencia por calor y el umbral de alerta propuesto.
- La respuesta a las preguntas analíticas y una recomendación concreta para la empresa.

No se exige un valor mínimo de las métricas. Se evalúan la calidad de la preparación de los datos, la validación, la comparación contra las líneas base y sobre todo la interpretación de los resultados, según la rúbrica.

Recursos Disponibles

Recurso	Dónde encontrarlo	Para qué sirve
Datos	Kaggle (cuenta gratuita, botón Download): https://www.kaggle.com/datasets/anikannal/solar-power-generation-data	Usar solo Plant_1_Weather_Sensor_Data.csv y Plant_2_Weather_Sensor_Data.csv
Diccionario de datos	Anexo A de este documento	Significado y unidades de cada columna
Ayudas de código probadas	Anexo B de este documento	Ubicar los datos, crear rezagos y calcular la línea base de persistencia en ambas plantas
Plantilla del informe	Plantilla IEEE del curso (“Formato presentación documentos”) en la plataforma del curso	Formato obligatorio del informe
Rúbrica	Sección “Rúbrica de evaluación” de este documento	Criterios, pesos y evidencias que se calificarán
Acompañamiento	Sesiones 13 a 16: asesoría y revisión de avances	Resolver dudas antes de la entrega

Ruta del Proyecto (CRISP-DM)

El proyecto sigue las fases de la metodología CRISP-DM vista en la sesión 2. Cada tarea de este enunciado corresponde a una o más fases:

Fase CRISP-DM	Tarea del proyecto	Pregunta que responde
Comprensión del negocio	Tarea 1: Contexto Térmico y Operativo del Módulo	¿Por qué se calienta el módulo, cuánto le cuesta ese calor a la planta y qué preguntas analíticas vamos a responder?
Comprensión de los datos	Tarea 2 (datos de Kaggle y EDA)	¿Qué datos tenemos, qué tan completos son y qué patrones muestran?
Preparación de los datos	Tarea 2 (faltantes, atípicos, variables)	¿Qué decisiones de limpieza y transformación tomamos y por qué?
Modelado	Tarea 3	¿Qué modelos usamos y cómo ajustamos sus hiperparámetros?
Evaluación	Tareas 3 y 4	¿El modelo supera la línea base y responde las preguntas del negocio?
Despliegue (propuesta)	Tarea 4 (conclusiones) y sustentación	¿Cómo usaría la empresa el modelo y qué haría falta para ponerlo en operación?

Cronograma Sugerido (4 Semanas)

Las fechas de **entrega (martes 24 de noviembre)** y de **sustentación (miércoles 25 de noviembre)** son obligatorias. Las metas semanales son una guía; las revisiones de las sesiones son formativas y no se califican por separado.

Sem.	Fechas	Qué deben hacer	Producto de la semana	En clase
1	28 oct – 3 nov	Tarea 1 (contexto y preguntas analíticas) y descarga de los archivos de sensores de ambas plantas	Introducción con fuentes y datos cargados	Sesión 13 (28 oct): atípicos e imputación
2	4 – 10 nov	Tarea 2: calidad de datos, faltantes, atípicos y EDA	Dataset limpio y gráficos del EDA	Sesión 14 (4 nov): asesoría del proyecto
3	11 – 17 nov	Tarea 3: modelos de regresión con validación y prueba en la Planta 2	Tabla comparativa de modelos	Sesión 15 (11 nov): Parcial 3 y avances
4	18 – 24 nov	Tarea 4: informe IEEE, limpieza del notebook y diapositivas	Entrega final (martes 24 nov)	Sesión 16 (18 nov): revisión de avances
—	25 nov	Sustentación	Presentación y defensa	Semana 17 (miércoles 25 nov)

Reglas de Juego: Uso de IA Generativa

De acuerdo con los acuerdos sobre IAG del syllabus del curso y el Manifiesto sobre IA y educación de la Universidad Icesi, este proyecto se desarrolla como máximo en el **Nivel 3 – Colaboración con IAG**. Pueden apoyarse en la IAG para completar tareas y mejorar sus productos, pero llevando un registro de sus interacciones y demostrando que entienden y pueden modificar todo lo generado.

Qué está permitido

- Pedir explicaciones de conceptos, de funciones de pandas y scikit-learn o de mensajes de error.
- Generar o depurar fragmentos de código (gráficos, limpieza, ajuste de modelos), siempre que el grupo lo revise, lo ejecute, lo entienda y pueda modificarlo.
- Mejorar la redacción y la ortografía del informe y de las diapositivas.
- Buscar fuentes para la Tarea 1, verificando cada una en el documento original antes de citarla.

Qué no está permitido

- Entregar código, texto o figuras que ningún integrante pueda explicar o modificar.

- Delegar en la IAG las decisiones del proyecto y su sustentación (qué variables usar, cómo tratar faltantes y atípicos, qué modelo elegir) o la interpretación de resultados, la discusión y las conclusiones: esas son las evidencias de aprendizaje que se evalúan.
- Citar fuentes, cifras o resultados sin verificarlos: la IAG puede inventar referencias y datos.

Registro y declaración (obligatorios)

- **Declaración en el informe:** un párrafo antes de las referencias con el nivel usado, las herramientas, para qué se usaron y cómo se verificó lo generado.

Cómo se verifica

- En la sustentación, cualquier integrante puede ser llamado a explicar o modificar en vivo cualquier parte del notebook o del informe. La rúbrica (criterio 5, 30 %) ubica en nivel Developing la "dependencia significativa de herramientas de IA sin comprensión plena de lo generado".
- Entregar sin registro, con contenido que el grupo no puede explicar o con fuentes inventadas afecta la calificación de los criterios correspondientes y puede tratarse como falta a la integridad académica según el reglamento de la Universidad.

Contexto Térmico y Operativo del Módulo (Tarea 1)

Investiguen y documenten en la introducción del informe, con al menos **cinco fuentes confiables** citadas en formato IEEE (UPME, IDEAM, fabricantes de módulos, artículos científicos):

- **Energía solar en Colombia:** ¿cuánta capacidad solar tiene el Sistema Interconectado Nacional y cómo ha crecido? ¿Qué temperaturas ambiente y niveles de irradiación tienen ciudades como Cali (Atlas de Radiación Solar del IDEAM)?
- **Física del módulo:** ¿por qué el módulo se calienta más que el aire? ¿Qué es la temperatura nominal de operación de la celda (NOCT) y qué dicen modelos sencillos como el de Ross sobre la relación entre irradiación y calentamiento?
- **Impacto en la potencia:** ¿qué es el coeficiente de temperatura de la potencia de un módulo y cuánto se pierde típicamente por cada grado de aumento?
- **Operación y mantenimiento:** ¿qué son los puntos calientes (hot spots) y cómo se detectan? ¿Cómo influyen el viento y el tipo de montaje en la temperatura del módulo?

Preguntas analíticas

Con base en lo investigado, formulen **dos o tres preguntas analíticas** que su proyecto responderá con los datos, y retómenlas en la discusión. Ejemplo: "¿Cuántos grados por encima del aire se calienta el módulo por cada kW/m² de irradiación, y es igual en las dos plantas?"

Comprensión y Preparación de los Datos (Tarea 2)

2.1 Descarga y construcción del dataset

- **Descarga:** entren a la página del dataset en Kaggle (cuenta gratuita), usen el botón **Download** y guarden el ZIP (archive.zip). Kaggle se usa solo para descargar los datos; el trabajo se hace en **Jupyter en su equipo** (recomendado) o en **Google Colab**.
- **Local:** creen una carpeta del proyecto, pongan allí el notebook y el ZIP (o los CSV descomprimidos) e instalen las librerías con `pip install pandas scikit-learn matplotlib`. **Colab:** suban el ZIP con el panel de archivos (queda en /content) o léanlo desde Google Drive. En ambos casos la función `buscar_datos` del Anexo B encuentra los CSV y descomprime el ZIP si hace falta.
- Usen solo **Plant_1_Weather_Sensor_Data.csv** y **Plant_2_Weather_Sensor_Data.csv**. Los archivos de generación no son necesarios.
- Conviertan DATE_TIME a fecha y creen variables derivadas justificadas (por ejemplo, la hora del día en decimal).

2.2 Selección de variables

- Elijan y justifiquen los predictores con base en la Tarea 1 (AMBIENT_TEMPERATURE, IRRADIATION, hora).
- **Valores pasados de la señal (rezagos):** pueden usar como predictores valores anteriores de MODULE_TEMPERATURE (por ejemplo, de hace 15, 30 y 60 minutos), porque en la operación ya se conocen. Calcúlenlos con la fecha y no con la posición de la fila (función `agregar_rezagos` del Anexo B), también en la Planta 2. Comparen los modelos con y sin rezagos.
- **Justifiquen lo que descartan:** MODULE_TEMPERATURE del mismo instante y cualquier variable calculada con ella (por ejemplo, la diferencia entre la temperatura del módulo y la ambiente) sirven para explorar, pero usarlas como predictor es fuga de información. Solo sus valores pasados son válidos.

2.3 Faltantes, atípicos y calidad de datos

- **Registros ausentes:** calculen cuántos instantes de 15 minutos deberían existir en el periodo y cuántos faltan en cada planta. ¿Cuál planta tiene más huecos?
- **Día y noche:** de noche no hay irradiación y el módulo puede quedar **más frío que el aire**. Decidan si modelan el día completo o solo las horas de sol, y justifiquen con gráficos.
- **Atípicos:** identifíquenlos con una técnica estadística sencilla (rango intercuartílico o puntaje z, sesión 13) y decidan, caso por caso, si son errores de registro o eventos reales. No eliminen datos sin justificarlo.
- **Imputación:** usen técnicas sencillas y justificadas (mediana por grupo, interpolación en el tiempo). Si imputan, comparen la distribución antes y después.

2.4 Análisis exploratorio

- Histogramas y boxplots de las tres variables en cada planta: ¿las dos plantas tienen el mismo clima?
- MODULE_TEMPERATURE vs. AMBIENT_TEMPERATURE y vs. IRRADIATION, y la diferencia (módulo - ambiente) vs. IRRADIATION: ¿la relación es lineal?, ¿es igual en las dos plantas?
- Perfil diario promedio de las tres variables y matriz de correlación.

Modelado y Evaluación (Tarea 3)

Vayan de lo simple a lo complejo y comparen siempre contra una línea base. Todo con scikit-learn, como en las sesiones 8 a 10.

3.1 Regresión: temperatura del módulo (Planta 1)

- **Líneas base:** regresión lineal simple con la temperatura ambiente como única variable, y **persistencia** (la temperatura del módulo de los 15 minutos anteriores).
- **Regresión lineal múltiple:** interpreten los coeficientes y compárenlos con la física investigada: ¿cuántos °C se calienta el módulo por cada kW/m² de irradiación? Revisen los supuestos con el gráfico de residuos vs. valores predichos y el histograma de residuos. Opcional: p-values con statsmodels.
- **Árbol de decisión de regresión:** elijan la profundidad máxima con validación cruzada. ¿Supera a la regresión lineal? Si no, expliquen por qué con la física del problema.
- **Métricas:** R^2, RMSE y MAE en el conjunto de prueba, y gráfico de valores reales vs. predichos del mejor modelo.

3.2 Validación

- Dividan los datos de la Planta 1 **cronológicamente por días**: los primeros días (aprox. 80 %) para entrenamiento y los últimos (aprox. 20 %) para prueba. Expliquen por qué no conviene mezclar al azar registros consecutivos de 15 minutos.
- Ajusten hiperparámetros con **validación cruzada de 5 particiones para series de tiempo** (TimeSeriesSplit de scikit-learn) sobre el entrenamiento ordenado por fecha.
- El escalado y la imputación se ajustan **solo con el conjunto de entrenamiento** (usen Pipeline de scikit-learn).
- **Sobreajuste:** comparen la métrica principal en entrenamiento y en prueba para cada modelo y comenten si hay sobreajuste.

3.3 Prueba en la Planta 2

- Apliquen los modelos entrenados con la Planta 1, **sin reentrenarlos**, a los datos de la Planta 2 y reporten las mismas métricas.

- Ajusten una regresión lineal múltiple solo con la Planta 2 y comparen sus coeficientes con los de la Planta 1. ¿Qué diferencias físicas (montaje, ventilación, tipo de módulo) podrían explicarlas?

3.4 Uso para el negocio

- **Pérdidas por calor:** con el coeficiente de temperatura de la potencia investigado en la Tarea 1, estimen el porcentaje de potencia que se pierde por calor respecto a la temperatura de referencia de 25 °C (condiciones estándar de prueba), usando el promedio de las horas de sol de la Planta 1.
- **Umbral de alerta:** a partir de la distribución de los residuos del modelo en entrenamiento (por ejemplo, el percentil 99 o tres desviaciones estándar), propongan cuántos grados por encima de lo predicho indicarían un módulo con problemas, y cuántas alertas habría generado ese umbral en el periodo de prueba.

Informe Final (Tarea 4)

Documento técnico de **máximo 5 páginas** en la plantilla IEEE del curso ("Formato presentación documentos"). No anexen el código al documento. Estructura:

- **Título, autores y resumen (150–250 palabras)** e índice de términos (cuatro palabras clave).
- **Introducción:** problema de negocio, contexto de la Tarea 1, objetivos y preguntas analíticas.
- **Materiales y métodos:** datos, variables seleccionadas, manejo de faltantes y atípicos, modelos, validación, métricas y versiones de las librerías.
- **Resultados:** tabla comparativa de todos los modelos (incluida la línea base) y las figuras principales, presentados sin interpretar.
- **Discusión:** respuesta a las preguntas analíticas, interpretación a la luz del negocio y limitaciones. Por ejemplo: "La regresión lineal superó al árbol de decisión porque la relación entre irradiación y calentamiento del módulo es aproximadamente lineal, como predice el modelo de Ross".
- **Conclusiones:** utilidad del modelo para la toma de decisiones, cómo lo usaría la empresa (despliegue) y mejoras concretas.
- **Declaración de uso de IAG:** un párrafo antes de las referencias con el nivel usado, las herramientas, para qué se usaron y cómo se verificó lo generado (si no usaron IAG, decláranlo).
- **Referencias** en formato IEEE.

Sustentación (miércoles 25 de noviembre)

- **Duración:** 12 minutos de presentación y 8 minutos de preguntas por grupo. Todos los integrantes presentan.
- **Contenido:** problema y preguntas analíticas, decisiones de preparación de datos, modelos y resultados, respuesta a las preguntas y recomendación para la empresa.

- **Preguntas individuales:** el docente puede pedir a cualquier integrante que explique o modifique en vivo una parte del notebook. Los criterios 1 a 4 de la rúbrica se califican por grupo; el criterio 5 (sustentación, 30 %) se califica de forma individual.

Evidencias que se Revisarán en este Proyecto

Criterio	Qué se espera ver
1. Claridad y Rigor en el Análisis	Carga correcta de los sensores de ambas plantas; registros ausentes comparados entre plantas; decisión justificada sobre el día completo o solo horas de sol; atípicos con IQR o z; relación temperatura–irradiación analizada en ambas plantas.
2. Desarrollo y Ajuste de los Modelos	Rezagos justificados y comparados con la persistencia; coeficiente de la irradiación interpretado en °C por kW/m² y comparado con la física (NOCT, modelo de Ross); residuos revisados; profundidad del árbol justificada; explicación de por qué un modelo lineal puede superar al árbol; coeficientes de ambas plantas comparados.
3. Validación y Métricas	División cronológica por días y validación cruzada para series de tiempo; R^2, RMSE y MAE frente a la línea base; comparación entrenamiento vs. prueba; métricas en la Planta 2 sin reentrenar y lectura crítica de la transferencia.
4. Comunicación de Resultados	Informe IEEE de máximo 5 páginas con tabla comparativa, real vs. predicho, residuos, comparación entre plantas y estimación de pérdidas por calor, explicadas en el texto; preguntas analíticas respondidas.
5. Sustentación Oral (Presentación)	Explicar la física del calentamiento del módulo, por qué la diferencia módulo - ambiente es fuga, cómo se propuso el umbral de alerta y defender o modificar el código sin apoyo de la IAG.

Entregables

Cómo entregar: un solo envío por grupo en la plataforma del curso, a más tardar el **martes 24 de noviembre de 2026 a las 11:59 p. m.**, en un archivo ZIP llamado **Proyecto5_Grupo_ApellidosMiembros.zip** con los tres archivos siguientes. No incluyan los CSV del dataset.

- **Notebook (.ipynb, Jupyter local o descargado de Google Colab):** documentado, ejecutado de principio a fin con las salidas visibles y con semilla aleatoria fija (random_state = 42).
- **Informe final:** PDF de máximo 5 páginas en la plantilla IEEE del curso.
- **Diapositivas** de la sustentación (PDF).

Rúbrica de Evaluación

Criterio	Peso	Outstanding (4.5 – 5.0)	Proficient (3.8 – 4.5)	Developing (3.0 – 3.8)	Beginning (0 – 3.0)
1. Claridad y Rigor en el Análisis	17.5 %	El EDA está bien estructurado, con gráficos claros y justificaciones sólidas y profundas sobre cada decisión de preprocesamiento.	El EDA está completo y ordenado, con justificaciones adecuadas para las decisiones tomadas.	El EDA presenta cierta estructura, pero carece de justificaciones claras o consistencia en las decisiones.	El EDA es superficial, desorganizado o con ausencia de justificaciones relevantes.
2. Desarrollo y Ajuste de los Modelos	17.5 %	Implementación e interpretación correcta de modelos; se interpretan correctamente los resultados, se discuten supuestos y se analizan las variables relevantes.	Modelos correctamente implementados; interpretación y análisis adecuados, aunque con menor profundidad.	Modelos funcionales, pero con errores de interpretación o sin discusión de supuestos/variables.	Modelos mal implementados o no interpretados; sin relación con los objetivos del taller.
3. Validación y Métricas	17.5 %	Aplicación de validación cruzada o estrategias pertinentes; uso acertado de métricas y análisis crítico profundo.	Validación bien ejecutada y métricas adecuadas; el análisis crítico es correcto, aunque puede mejorar.	Uso básico de validación y métricas; análisis poco crítico o limitado.	Validación incorrecta o ausente; métricas mal utilizadas o mal interpretadas.
4. Comunicación de Resultados	17.5 %	Informe claro, bien estructurado y argumentado; visualizaciones claras, relevantes y bien explicadas.	Informe claro y coherente; visualizaciones adecuadas, aunque podrían mejorar en diseño o explicación.	Informe con deficiencias de estructura o claridad; visualizaciones poco efectivas o incompletas.	Informe confuso o incompleto; visualizaciones ausentes o sin valor analítico.
5. Sustentación Oral (Presentación)	30 %	Domina con seguridad los conceptos técnicos y metodológicos del trabajo; justifica cada decisión (preprocesamiento, selección de modelo, métricas) con argumentos propios y contextualizados; explica y defiende su código sin depender de notas, respondiendo con solvencia preguntas no anticipadas.	Explica con claridad la mayoría de los conceptos y decisiones del trabajo, aunque con menor profundidad en algunos puntos; justifica adecuadamente las decisiones metodológicas; explica su código de forma correcta, con apoyo ocasional en notas o documentación propia.	Presenta el trabajo con explicaciones superficiales o memorísticas; tiene dificultad para justificar decisiones metodológicas sin ayuda del evaluador; su explicación del código es parcial o evidencia dependencia significativa de herramientas de IA sin comprensión plena de lo generado.	No logra explicar los conceptos ni justificar las decisiones tomadas; no puede explicar o defender el código presentado; depende casi por completo de las indicaciones del evaluador para sostener cualquier parte de la presentación.

Anexo A: Diccionario de Datos (sensores de ambas plantas)

Periodo: 15-may-2020 a 17-jun-2020, registros cada 15 minutos. Cada archivo de sensores contiene solo las seis columnas indicadas. Las variables marcadas como "Construida" no están explícitas en el conjunto de datos: debe construirlas el equipo, algunas con las ayudas de código ubicadas al final o con el código que consideren pertinente.

Variable	Archivo	Descripción	Unidad
DATE_TIME	Sensores	Fecha y hora del registro	—
PLANT_ID	Sensores	Identificador de la planta	—
SOURCE_KEY	Sensores	Identificador del sensor	—
AMBIENT_TEMPERATURE	Sensores	Temperatura ambiente de la planta	°C
MODULE_TEMPERATURE	Sensores	**Variable objetivo:** temperatura del módulo	°C
IRRADIATION	Sensores	Irradiación sobre el plano del módulo (promedio de 15 min)	kW/m²
MODULE_TEMPERATURE_lag1 / _lag2 / _lag4	Construida	Temperatura del módulo 15, 30 y 60 minutos antes (predictores permitidos)	°C

Anexo B: Ayudas de Códigos

Son solo funciones de apoyo y la línea base de persistencia: la construcción del dataset, la división de los datos y los modelos los programa cada grupo. Prepárense para comprender y explicar también su funcionamiento en la sustentación.

1. Ubicación de los datos descargados de Kaggle (local o Colab)

```
import glob, os, zipfile
def buscar_datos(archivo='Plant_1_Weather_Sensor_Data.csv', carpeta='.'):
    """Devuelve la carpeta donde están los CSV del dataset descargado de Kaggle.
    Antes de ejecutar: descarguen el ZIP (botón Download en Kaggle) y déjenlo, o los CSV,
    dentro de `carpeta`:
    - Local (Jupyter): la carpeta del proyecto donde está el notebook (carpeta='.').
    - Colab: súbanlo con el panel de archivos (/content, carpeta='.') o desde Google Drive
      (carpeta='/content/drive/MyDrive/<su_carpeta>').
    Si encuentra el ZIP sin descomprimir, lo descomprime en <carpeta>/datos_solar."""
    hallados = glob.glob(os.path.join(carpeta, '**', archivo), recursive=True)
    if hallados:
        return os.path.dirname(hallados[0])
    for ruta_zip in glob.glob(os.path.join(carpeta, '*.zip')):
        with zipfile.ZipFile(ruta_zip) as z:
            if any(n.endswith(archivo) for n in z.namelist()):
                destino = os.path.join(carpeta, 'datos_solar')
                z.extractall(destino)
                return buscar_datos(archivo, destino)
    raise FileNotFoundError(f'No se encontró {archivo}. Descarguen el ZIP desde Kaggle y déjenlo '
                            'en la carpeta del notebook, o indiquen la ruta con el argumento carpeta.')
ruta = buscar_datos()
print('Datos en:', ruta, '->', sorted(os.listdir(ruta)))
```

2. Función para agregar valores pasados (rezagos)

```
import numpy as np
import pandas as pd
def agregar_rezagos(df, columna, pasos=(1, 2, 4), freq='15min'):
    """Agrega a df columnas con valores pasados de `columna` (rezagos).
    pasos: intervalos hacia atrás (con freq='15min': 1 = 15 min, 2 = 30 min, 4 = 1 hora).
    El rezago se busca por fecha y no por posición de fila: si falta el registro
    anterior, el valor queda vacío (NaN) en lugar de tomar uno equivocado.
    Requiere una columna DATE_TIME sin fechas repetidas. Úsenla ANTES de filtrar las horas de sol."""
    serie = df.set_index('DATE_TIME')[columna]
    if not serie.index.is_unique:
        raise ValueError('Hay fechas repetidas: agreguen o eliminen duplicados primero.')
    for p in pasos:
        pasado = serie.shift(p, freq=freq)       # el valor de t queda asociado a t + p intervalos
        df[f'{columna}_lag{p}'] = df['DATE_TIME'].map(pasado)
    return df
# Uso: df = agregar_rezagos(df, 'NOMBRE_DE_LA_COLUMNA')   -> crea NOMBRE_lag1, NOMBRE_lag2, NOMBRE_lag4
```

3. Líneas base de persistencia (Planta 1 y Planta 2)

```
# Líneas base de persistencia: la temperatura del módulo de los 15 minutos anteriores.
# Requiere `test` (prueba de la Planta 1) y `p2` (Planta 2) con MODULE_TEMPERATURE y
# MODULE_TEMPERATURE_lag1 (agregar_rezagos).
from sklearn.metrics import r2_score, mean_absolute_error, mean_squared_error


for nombre, d in [('Planta 1 (prueba)', test), ('Planta 2', p2)]:
    d = d.dropna(subset=['MODULE_TEMPERATURE_lag1'])
    real, pred = d['MODULE_TEMPERATURE'], d['MODULE_TEMPERATURE_lag1']
    print(f'Persistencia {nombre:<18} R2 = {r2_score(real, pred):.3f}   '
          f'RMSE = {np.sqrt(mean_squared_error(real, pred)):.2f} °C   MAE = {mean_absolute_error(real,
pred):.2f} °C')
```